



FACULDADE DE
CIÊNCIAS E TECNOLOGIA
UNIVERSIDADE D
COIMBRA



ENGENHARIA DE CARACTERÍSTICAS PARA APRENDIZAGEM
COMPUTACIONAL

CLASSIFICAÇÃO DE ATIVIDADES HUMANAS

Trabalho realizado por:

Luciana Oliveira Rocha — 2022226251

Pedro Henrique Gabarra Sandoval — 2022127668

Introdução

Este relatório detalha o desenvolvimento de um trabalho prático focado na aplicação e exercitação de conceitos fundamentais em uma pipeline completa de análise de dados. O problema central abordado neste trabalho é a classificação e reconhecimento de atividades físicas humanas, um campo de estudo com relevância crescente em diversas áreas, incluindo aplicações médicas, recreativas e de bem-estar.

Para tal, utilizamos o dataset FORTH-TRACE benchmark, um conjunto de dados robusto adquirido a partir de 15 participantes, registrando 16 atividades distintas. Este dataset é particularmente rico, pois integra informações de 5 sensores localizados em diferentes partes do corpo (pulsos, peito e pernas), capturando dados de aceleração, velocidade angular e variação do campo magnético.

Serão detalhadas as abordagens para identificação e tratamento de outliers, utilizando técnicas univariadas e multivariadas como o teste Z-Score e o algoritmo K-Means. Isso incluirá a análise de significância estatística, a implementação de feature sets temporais e espectrais e a aplicação de métodos de redução de dimensionalidade como a Análise de Componentes Principais (PCA), bem como técnicas de seleção de características como Fisher Feature Score e ReliefF.

Através desta abordagem estruturada, buscamos não apenas resolver o problema de classificação proposto, mas também solidificar a compreensão dos princípios que governam uma pipeline de análise de dados eficiente e robusta.


3. Análise e Tratamento de Outliers

O objetivo do ponto 3 foi identificar e tratar outliers nos dados de sensores, utilizando tanto abordagens univariáveis quanto multivariáveis. Para isso, consideramos os vetores de aceleração, giroscópio e magnetômetro. Para a análise, focámo-nos nos sensores do pulso direito, separando os dados por dispositivo.

3.1. Análise de Distribuição Univariada (Boxplots)

Para o ponto 3.1, o objetivo era criar vários boxplots com cada atividade relativa aos sujeitos e a cada uma das variáveis transformadas (as magnitudes calculadas inicialmente), separadas por dispositivo.

Para isto foi criada uma função chamada `boxplot_by_activity(df, variable, title)` que usa o `seaborn` para gerar os boxplots das variáveis `acc_mac` (magnitude da aceleração), `gyro_mag` (magnitude do giroscópio) e `mag_mag` (magnitude do magnetômetro).




Os boxplots permitem observar a variação das leituras dos sensores por atividade. Atividades mais dinâmicas, como andar, andar enquanto fala, subir escadas, subir escadas e falar, entre outros, apresentam maior dispersão, enquanto atividades mais estáticas, como estar em pé, sentar e sentar a falar, têm distribuições mais concentradas.

3.2. Identificação de Outliers via Método IQR

O método IQR foi aplicado para identificar valores atípicos segundo a regra de Tukey, usando a função `iqr_outliers(array)`. Os resultados mostraram variações significativas entre sensores e atividades:

- Aceleração: maior densidade de outliers em atividades com movimentos bruscos ou rotacionais, com destaque para atividades 8–11, que atingem entre 15% e 20% de outliers.
- Giroscópio: densidade moderada de outliers, refletindo movimentos rotacionais.
- Magnetômetro: geralmente baixa densidade de outliers, exceto em algumas atividades específicas.

O sensor de aceleração apresentou mais outliers que os restantes, consistente com a sua sensibilidade a alterações de movimento.



3.3. a 3.5. Identificação de Outliers via Z-Score (Univariado)


Para o método Z-Score, foi criada a função `zscore_outliers(array, k=3)` que marca como outlier qualquer valor cujo Z-Score exceda o limiar `kkk`. Para avaliar o impacto de diferentes limiares, utilizou-se a função `compare_zscores(df, variable, k_list=[3, 3.5, 4])`.

Comparando com o IQR, o Z-Score tende a identificar menos outliers quando a distribuição dos dados é aproximadamente normal. Valores menores de k aumentam a sensibilidade, detetando mais outliers, enquanto valores maiores reduzem falsos positivos, mas podem deixar passar outliers reais. Para o giroscópio, k=3.5 mostrou-se adequado.

De forma geral, o IQR é mais robusto para distribuições não normais, enquanto o Z-Score é mais eficiente para dados simétricos. Ambos os métodos identificam padrões semelhantes, embora o IQR seja geralmente mais conservador.

Resumo dos resultados de densidade total de outliers (Z-Score, k=3.5):


- Aceleração: 0.56%
- Giroscópio: 0.70%
- Magnetômetro: 0.06%



3.6. e 3.7. Identificação de Outliers via K-Means (Multivariado)

Para a abordagem multivariada, utilizamos o algoritmo K-Means para agrupar os dados tridimensionais (x, y, z) e identificar outliers baseados na distância de cada ponto ao centroide do seu cluster.

Inicialmente, uma abordagem de corte fixo (percentil 95, removendo os top 5% das maiores distâncias) provou ser excessiva e arbitrária. Para corrigir isto, aplicámos um Z-Score sobre as distâncias euclidianas aos centroides. Esta abordagem dinâmica revelou-se muito mais robusta.



O K-Means mostrou-se mais sensível que o Z-Score univariado, pois deteta anomalias na correlação entre eixos (ex: um valor de x normal, mas impossível quando combinado com um certo valor de y), algo que a análise eixo-a-eixo ignora. Abaixo apresenta-se a comparação final das densidades de outliers detetadas:

Tabela 3.6: Comparação de Densidade de Outliers


Método	Aceleração	Giroscópio	Magnetômetro	Observação
Z-Score Univariado (k=3.5)	0.56%	0.70%	0.06%	Conservador; ignora correlação espacial.
K-Means (Distância Z-Score)	~1.2%	~1.5%	~0.2%	Recomendado: Multivariado e adaptativo.

3.7.1. Bónus: Detecção Avançada de Outliers com DBSCAN


Como complemento à análise de outliers e procurando superar as limitações do K-Means (que força a criação de clusters esféricos e exige a definição prévia de k), implementou-se o algoritmo DBSCAN (Density-Based Spatial Clustering of Applications with Noise).

O DBSCAN agrupa pontos baseando-se na densidade local, classificando como ruído (outliers) os pontos que residem em regiões de baixa densidade.


- Pré-processamento: os dados foram normalizados (StandardScaler) para garantir a equiparação das escalas dos eixos.
- Amostragem: dado o elevado custo computacional do algoritmo e o volume massivo do dataset original (>700.000 amostras), aplicou-se uma amostragem aleatória estratificada de 50.000 pontos. Esta abordagem permitiu obter resultados representativos em tempo útil sem comprometer a integridade estatística da distribuição.
- Parâmetros: definiu-se um raio de vizinhança $eps=0.5$ e um mínimo de $min_samples=10$.



Aceleração - 3D




Giroscópio: gyro_x vs gyro_y




DBSCAN - Giroscópio


Giroscópio: gyro_x vs gyro_z




Giroscópio: gyro_y vs gyro_z



Giroscópio - 3D




Magnetômetro: mag_x vs mag_y





DBSCAN - Magnetômetro

Magnetômetro: mag_x vs mag_z



Magnetômetro: mag_y vs mag_z





A aplicação do algoritmo permitiu isolar o ruído com elevada precisão, revelando os seguintes padrões:

- Aceleração: Foram identificados 3 clusters principais, com apenas 202 outliers (0.40%). Isto demonstra uma elevada consistência nos dados de movimento linear.
- Giroscópio: O algoritmo detetou 2 clusters e marcou 1.074 outliers (2.15%), indicando que os movimentos rotacionais apresentam uma maior variabilidade e ruído nas extremidades da distribuição.
- Magnetômetro: Contrariamente à análise inicial com métodos mais simples, o DBSCAN revelou uma estrutura muito coesa nos dados magnéticos, agrupando a quase totalidade das amostras em apenas 2 clusters. Foram isolados apenas 46 outliers (0.09%), o que sugere que as leituras magnéticas, apesar da sua geometria complexa (esférica), mantêm uma densidade contínua muito forte, com poucas anomalias reais isoladas.

4. Engenharia de Características

4.1. Análise de Significância Estatística

O Item 4.1 pedia-nos para determinar a significância estatística dos seus valores médios nas diferentes atividades, com base nos nossos estudos anteriores e utilizando a sugestão dada na proposta do projeto, obtivemos o seguinte resultado:

Tabela 4.1: Testes de Normalidade (Kolmogorov-Smirnov) - Magnetômetro			
Atividade	Nº de Amostras	P-value	Conclusão
Climb Stair (up/down)	89.359	0.0000	Não Normal
Climb Stair (up/down) and talk	43.791	0.0000	Não Normal

Climb stairs (up/down) -> walk	1.905	0.0000	Não Normal
Climb stairs (up/down) and talk -> walk and talk	1.905	0.0020	Não Normal
Sit	83.968	0.0000	Não Normal
Sit and Talk	81.152	0.0000	Não Normal
Sit -> Stand	5.632	0.0000	Não Normal
Sit -> Stand and talk	5.376	0.0000	Não Normal
Stand	157.882	0.0000	Não Normal
Stand -> climb stairs (up/down) (& talk)	3.810	0.0000	Não Normal
Stand -> Sit	6.656	0.0000	Não Normal
Stand -> Sit and talk	6.656	0.0000	Não Normal
Stand -> walk	3.810	0.0000	Não Normal
Walk	139.934	0.0000	Não Normal
Walk and Talk	142.366	0.0000	Não Normal
Walk -> stand	7.620	0.0000	Não Normal

Uma ou mais distribuições não são normais ou têm amostras pequenas. Usando o teste Kruskal-Wallis (não-paramétrico).

Resultado do Kruskal-Wallis H-test para a magnitude de Magnetômetro:

Estatística: 139236.1550

P-valor: 0.0000

Todos os testes de Kolmogorov-Smirnov resultaram em p-valores extremamente baixos (0.0000 ou 0.0020), os resultados nos causaram estranheza, porém os cálculos estavam aparentemente corretos, que são significativamente inferiores ao nível de significância usual de 0.05.

Este resultado nos leva a rejeitar a hipótese nula de que as distribuições da magnitude do magnetômetro dentro de cada atividade seguem uma distribuição normal.

A não-normalidade dos dados é um achado comum em dados de sensores de atividades humanas, dada a natureza complexa e não-linear dos movimentos. Dada a violação da suposição de normalidade, inviabilizando o uso de testes paramétricos como a Análise de Variância (ANOVA), optou-se pela aplicação de um teste não-paramétrico apropriado.

O teste de Kruskal-Wallis H-test foi selecionado por ser a alternativa não-paramétrica para comparar três ou mais grupos independentes, avaliando se as medianas (ou a distribuição dos ranks) são significativamente diferentes entre os grupos.

Comentário e Implicações:

Com um p-valor de 0.0000, que é drasticamente menor do que qualquer nível de significância comum (e.g., $\alpha = 0.05$), rejeitamos enfaticamente a hipótese nula. A hipótese nula neste contexto seria que as medianas (ou distribuições de ranks) da magnitude do magnetômetro são iguais em todas as 16 atividades humanas.

A rejeição da hipótese nula indica que existe uma diferença estatisticamente significativa nas magnitudes do magnetômetro entre, pelo menos, algumas das atividades analisadas. Em termos práticos, isso significa que a magnitude do magnetômetro não se comporta da mesma forma para todas as atividades. Esta variabilidade observada entre as classes de atividade é uma propriedade extremamente desejável para uma feature em um problema de classificação.

Portanto, a magnitude do magnetômetro demonstra ser uma característica promissora e altamente discriminatória para diferenciar as atividades humanas. A inclusão desta feature na pipeline de classificação de atividades humanas é justificada, pois ela carrega informações valiosas que podem ser exploradas por um modelo de aprendizagem computacional para distinguir entre as diferentes ações realizadas pelos participantes. Este achado sugere que, ao invés de ser um ruído, as variações do campo magnético capturadas pelos sensores são reflexos distintos das diferentes atividades corporais.

4.2. Extração de Características

A extração de características foi realizada através do janelamento dos sinais, calculando-se as métricas apresentadas na Tabela 4.2.

Tabela 4.2 — Resumo das Features Extraídas	
Domínio	Features Calculadas
Temporal	Média, Desvio Padrão, Variância, Mínimo, Máximo, Mediana, Amplitude, Curtose, Assimetria (Skewness), RMS, Zero Crossing Rate (ZCR).
Espectral	Energia, Frequência Dominante, Entropia, Largura de Banda, Centróide.

4.3 e 4.4. Redução de Dimensionalidade com PCA

Nesta etapa, aplicamos a Análise de Componentes Principais (PCA) ao conjunto de dados normalizado gerado no item anterior, visando reduzir a dimensionalidade mantendo a informação essencial. O critério definido para a seleção das componentes foi a retenção de, pelo menos, 75% da variância total dos dados originais.

Análise da Variância Explicada

A importância de cada componente principal é determinada pela quantidade de variância que esta explica. Ao analisarmos a variância cumulativa, obtivemos os seguintes resultados:

- Componente 1 (C1): Explica aproximadamente 52,44% da variância total.
- Componente 2 (C2): Com a adição desta componente, a variância cumulativa sobe para 69,52%.
- Componente 3 (C3): A inclusão da terceira componente eleva a variância cumulativa para 76,70%.

Como se observa, a terceira componente permite ultrapassar o limiar estabelecido de 75%. Consequentemente, o dataset original foi reduzido para apenas 3 componentes principais, que foram armazenados no ficheiro `pca_features_dataset.csv`.

Considerações sobre a Aplicação do PCA:

- Vantagens: A principal vantagem observada foi a redução drástica da dimensionalidade (de centenas de features originais para apenas 3 componentes), o que facilita a visualização dos dados e reduz o ruído inerente à leitura dos sensores.
- Desvantagens: A redução implica uma perda de interpretabilidade direta, uma vez que as componentes principais são combinações lineares das features originais e não grandezas físicas diretas (como aceleração ou velocidade angular), podendo também ocorrer perda de informação subtil, mas relevante para a classificação.

Nota sobre Novos Exemplos:

Para projetar um novo exemplo (futuros dados de teste) neste espaço reduzido, é fundamental aplicar a mesma normalização utilizada no treino (subtraindo a média e dividindo pelo desvio padrão do conjunto de treino) e, a seguir, multiplicar o vetor resultante pela matriz de componentes principais ($W_{\{PCA\}}$) obtida nesta etapa.

4.5. Implementação dos Algoritmos de Seleção

Foram implementadas funções específicas para o cálculo do Fisher Score e do ReliefF. No caso do algoritmo ReliefF, devido à sua elevada complexidade computacional, a implementação foi otimizada através de vetorização matricial. Esta abordagem permitiu calcular as distâncias entre vizinhos de forma eficiente para todo o conjunto de dados, sem recorrer a ciclos lentos, garantindo a viabilidade da execução sobre as dezenas de milhares de amostras disponíveis. Os resultados (scores de cada feature) foram exportados para ficheiros CSV para análise posterior.

4.6. Comparação e Seleção de Features (Fisher Score vs. ReliefF)

Nesta etapa, comparámos os resultados dos métodos Fisher Score e ReliefF para seleccionar as 10 características mais relevantes (Top-10). Esta seleção visa reduzir a dimensionalidade do problema, mantendo apenas a informação mais discriminativa.

A comparação entre os dois métodos revelou uma consistência elevada, com uma interseção de 8 características comuns no Top-10.

Ranking	Fisher Score	ReliefF
Características Comuns	energy, variance, amplitude, max, std, rms, median, <i>participant_id</i>	energy, variance, amplitude, max, std, rms, median, participant_id*
Diferenças	mean, skewness	zcr, dominant_frequency

A variável *participant_id* surge no topo de ambos os rankings, o que confirma que existem padrões de movimento muito distintos entre indivíduos. No entanto, para efeitos de classificação de atividades, esta variável representa um viés. A sua utilização levaria o modelo a "memorizar" os participantes em vez de aprender os padrões universais das atividades, prejudicando a generalização para novos utilizadores. Portanto, esta feature deve ser descartada na fase de modelação.

O ReliefF atribuiu uma importância elevada ao zcr(2ª posição) e à dominant_frequency, características que capturam a frequência e oscilação do sinal. O Fisher Score, por basear-se mais em médias e variâncias globais, privilegiou características estatísticas de magnitude (mean, skewness). Isto sugere que o ReliefF consegue captar melhor as nuances não-lineares e locais do sinal.

Vantagens e Limitações da Abordagem de Seleção:

- Vantagens:
 - Interpretabilidade: Ao contrário do PCA, este método mantém as características originais, permitindo uma explicação física do modelo (ex: saber que a "Energia" é crucial para distinguir atividades).
 - Eficiência: A redução de dimensionalidade simplifica o modelo, diminuindo o custo computacional e o risco de overfitting por excesso de ruído.
- Limitações:
 - Independência: O Fisher Score avalia features individualmente, ignorando que certas variáveis podem ser fracas sozinhas, mas poderosas quando combinadas.
 - Custo: O ReliefF, embora detete interações, apresenta um custo computacional significativamente superior em datasets volumosos.